



EJERCICIOS CORTE 2 Parte 1
Septiembre de 2024

1. Considere los datos

$$Y = \begin{pmatrix} 3 & 10 \\ 6 & 12 \\ 5 & 14 \\ 10 & 9 \end{pmatrix}$$

y la hipótesis $H_0 : \mu' = (6, 11)$

- Verifique la hipótesis anterior para cada una de las medias en forma separada. Escriba los supuestos estadísticos requeridos, use $\alpha = 0.05$.
 - Verifique la hipótesis conjunta, use $\alpha = 0.05$.
2. Timm (1975, p. 23;; 1980, p. 47) informó los resultados de un experimento donde los sujetos respondieron a 'palabras de prueba' en cinco posiciones de una oración. Las variables son tiempos de respuesta para la j -ésima palabra de prueba, y_j , $j = 1, 2, \dots, 5$. Los datos se dan en el archivo Words.xlsx.
- Pruebe $H_0 : \mu = (30, 25, 40, 25, 30)$
 - Si la hipótesis nula se rechaza, pruebe cada variable separadamente.
3. Demuestre que la prueba t de observaciones pareadas

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}$$

tiene distribución t con $n - 1$ grados de libertad.

4. Los datos en ramus.csv (Elston y Grizzle 1962) consisten en mediciones Y_1 (8 años), Y_2 (8 años y medio), Y_3 (9 años), y Y_4 (9 años y medio), del hueso ramus a cuatro edades diferentes en 20 niños. Pruebe $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$ usando T^2 .
5. Tintner (1946) midió varios aspectos de los ciclos económicos para los bienes de consumo y los bienes de producción. Las variables son

Y_1 =duración del ciclo,
 Y_2 = porcentaje de subida de los precios,
 Y_3 = amplitud cíclica,
 Y_4 = tasa de variación.

Los datos de varios artículos se encuentran en ciclos.csv.



- a) Pruebe $H_0 : \mu_1 = \mu_2$ usando T^2 .
 - b) Calcule el vector $\mathbf{a} = S_p^{-1}(\bar{\mathbf{Y}}_1 - \bar{\mathbf{Y}}_2)$. A este vector se le conoce como **vector discriminante**
 - c) Escriba $\mathbf{a}'\mathbf{Y}$, donde $\mathbf{Y} = (Y_1, Y_2, Y_3, Y_4)$, esto nos indica qué variables contribuyen más a la separación de los grupos, mediante la combinación lineal. ¿Cuál de las variables contribuye más a la separación de los grupos?
6. 15 estudiantes escribieron un ensayo informal y otro formal (Kramer 1972, p. 100). Las variables registradas fueron el número de palabras y el número de verbos:

Y_1 = número de palabras en el ensayo informal,
 Y_2 = número de verbos en la redacción informal,
 X_1 = número de palabras del ensayo formal,
 X_2 = número de verbos de la redacción formal.

Como cada estudiante escribió ambos tipos de ensayos, los vectores de observación están emparejados. Los datos se encuentran en ensayo.xlsx.

- a) Pruebe $H_0 : \mu_d = 0$
 - b) Halle el vector de coeficientes de la función discriminante. $\mathbf{a} = S_d^{-1}\bar{\mathbf{d}}$
 - c) Realice una prueba t univariante en cada d_j .
7. Considere los resultados de la prueba estándar de tolerancia de glucosa administrada a 8 controles y a 10 pacientes obesos que se muestran en la tabla. Los datos (medidas del plasma de fosfato inorgánico), se determinaron a partir de muestras de sangre tomadas a 0, 0.5, 1, 1.5 y 2 horas después de una dosis estándar de glucosa suministrada oralmente ¿Apoyan los datos el supuesto que las matrices de covarianzas de las poblaciones de interés son iguales? Justifique su respuesta.

Control					Obesos				
0	0.5	1	1.5	2	0	0.5	1	1.5	2
4.3	3.3	3	2.6	2.2	4.3	3.3	3	2.6	2.2
3.7	2.6	2.6	1.9	2.9	5	4.9	4.1	3.7	3.7
4	4.1	3.1	2.3	2.9	4.6	4.4	3.9	3.9	3.7
3.6	3	2.2	2.8	2.9	4.3	3.9	3.1	3.1	3.1
4.1	3.8	2.1	3	3.6	3.1	3.1	3.3	2.6	2.6
3.8	2.2	2	2.6	3.8	4.8	5	2.9	2.8	2.2
3.8	3	2.4	2.5	3.1	3.7	3.1	3.3	2.8	2.9
4.4	3.9	2.8	2.1	3.6	5.4	4.7	3.9	4.1	2.8
3	2.5	2.3	2.2	2.1					
4.9	5	4.1	3.7	3.7					



EJERCICIOS CORTE 2 Parte 2
Septiembre de 2024

1. Para probar si existe una diferencia significativa entre cuatro laboratorios respecto al número de horas entre dos averías se obtuvieron los datos siguientes.

Laboratorio 1	Laboratorio 2	Laboratorio 3	Laboratorio 4
6.4	8.7	11.1	9.9
7.8	7.4	10.3	12.8
5.3	9.4	9.7	12.1
7.4	10.1	10.3	10.8
8.4	9.2	9.2	11.3
7.3	9.8	8.8	11.5

- a) Con un nivel de significancia de 0.05, ¿existe diferencia entre las medias poblacionales de los tiempos de los cuatro laboratorios?
- b) Si se han obtenido diferencias significativas entre los grupos, determina dónde se muestran esas diferencias utilizando el test de Tukey. Use un nivel de confianza de 99%.
- c) A partir de los residuos obtenidos, confirma la validez del modelo comprobando el cumplimiento de las 3 condiciones asumidas al hacer el ANOVA. ¿Crees que el modelo ANOVA utilizado es válido para estos datos? Use $\alpha = 0.01$.
2. Para estudiar el efecto de la temperatura en el rendimiento de un proceso químico, se produjeron cinco lotes con cada uno de los tres tratamientos. Los resultados se presentan a continuación. Dé la tabla para el análisis de varianza. Use $\alpha = 0.05$ para probar si la temperatura afecta el rendimiento medio del proceso.

Temperatura		
50°C	60°C	70°C
34	30	23
24	31	28
36	34	28
39	23	30
32	27	31

3. Los datos que se presentan en la siguiente tabla representan el número de horas de alivio proporcionadas por cinco marcas diferentes de tabletas para el dolor de cabeza administradas a 25 sujetos que tenían fiebre de 38°C o más. Realice el análisis de varianza y, a un nivel de significancia de 0.05, pruebe la hipótesis de que las cinco marcas proporcionan el mismo número medio de horas de alivio. Analice los resultados



Tabletas				
A	B	C	D	E
5.2	9.1	3.2	2.4	7.1
4.7	7.1	5.8	3.4	6.6
8.1	8.2	2.2	4.1	9.3
6.2	6.0	3.1	1.0	4.2
3.0	9.1	7.2	4.0	7.6

4. Los investigadores han sugerido que un cambio en el tamaño del cráneo a lo largo del tiempo es una prueba del mestizaje de una población residente con poblaciones inmigrantes. Se realizaron cuatro mediciones de cráneos egipcios masculinos correspondientes a tres periodos de tiempo diferentes: el periodo 1 es el 4000 a.C., el periodo 2 es el 3300 a.C. y el periodo 3 es el 1850 a.C. Los datos estan en craneo.xlsx. (Véanse los datos de los cráneos en el sitio web www.prenhall.com/statistics). Las variables medidas son las siguientes

X_1 = anchura máxima del cráneo (mm)

X_2 = altura basibregmática del cráneo (mm)

X_3 = longitud basalveolar del cráneo (mm)

X_4 = altura nasal del cráneo (mm)

- Realice un diagrama de cajas y bigotes para cada variable por año.
- Realice ANOVA para cada una de las variables.
- Construya un MANOVA unidireccional de los datos del cráneo egipcio. Use un nivel de significancia de 0.05.
- Construya intervalos de confianza simultáneos del 95 % para determinar qué componentes medios difieren entre las poblaciones representadas por los tres periodos de tiempo.

$$\bar{x}_{ki} - \bar{x}_{li} \pm t_{n-g, (\alpha/(pg(g-1)))} \sqrt{\frac{h_{ii}}{n-g} \left(\frac{1}{n_k} + \frac{1}{n_k} \right)}$$

h_{ii} es el i -ésimo elemento diagonal de $\mathbf{H}$.

- ¿Son realistas los supuestos MANOVA habituales para estos datos? Explíquelo.
5. Baten, Tack y Baeder (1958) compararon las puntuaciones de los jueces sobre el pescado preparado con tres métodos. Se cocinaron doce pescados con cada método, y varios jueces probaron muestras de pescado y puntuaron cada una de ellas según cuatro variables: Y_1 = *aroma*, Y_2 = *sabor*, Y_3 = *textura*, y Y_4 = *humedad*. Los datos se encuentran en pescados.xlsx. Cada entrada es una puntuación media de los jueces sobre ese pescado. Compare los tres métodos usando MANOVA.



EJERCICIOS CORTE 2 Parte 3

1. Considere un experimento en el que la resistencia (en horas) de determinado tipo de vidrio se evalúa para diferentes voltajes (en kilovoltios) y dos temperaturas 180 y 170 (en grados Celsius). A partir de las siguiente salida, conteste las preguntas:

Call:

```
lm(formula = Resistencia ~ Voltaje + Temperatura, data = vidrios)
```

Residuals:

Min	1Q	Median	3Q	Max
-57.005	-16.919	0.206	18.676	53.386

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	638.0753	10.8019	59.070	< 2e-16 ***
Voltaje	-1.1342	0.0337	-33.659	< 2e-16 ***
Temperatura180C	-33.4253	3.9504	-8.461	2.45e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 23.96 on 147 degrees of freedom

Multiple R-squared: 0.8865, Adjusted R-squared: 0.8849

F-statistic: 574 on 2 and 147 DF, p-value: < 2.2e-16

- a) ¿Cuántas observaciones hay en el estudio?
 - b) Interprete R^2 ajustado.
 - c) ¿Cuál es el modelo? Interprete los parámetros.
 - d) ¿Los parámetros son estadísticamente significativos para el modelo? Use un nivel de significancia de 0.01.
 - e) Construya los intervalos de confianza para los parámetros.
2. **Contexto de Negocio:** Usted es un científico de datos en una gran organización. Su empresa está pasando por una revisión interna de sus prácticas de contratación y compensación de empleados. En los últimos años, su empresa ha tenido poco éxito en la conversión de candidatas de alta calidad que deseaba contratar. La gerencia plantea la hipótesis de que esto se debe a una posible discriminación salarial y quiere averiguar qué lo está causando.

Problema de negocio: Como parte de la revisión interna, el departamento de recursos humanos se ha acercado a usted para investigar específicamente la siguiente pregunta:

- En general, ¿se les paga más a los hombres que a las mujeres en su organización? De ser así, ¿cuál es la causa de esta brecha?



Contexto Analítico: El departamento de recursos humanos le proporcionó una base de datos de empleados que contiene información sobre varios atributos, como desempeño, educación, ingresos, antigüedad, bonos, etc.

Objetivo: Usar técnicas de regresión en este conjunto de datos para resolver el problema comercial descrito anteriormente.

El caso está estructurado de la siguiente manera:

- a) Realice un análisis exploratorio de datos para investigar visualmente las diferencias en el pago.
 - b) Usar los conocimientos observados para ajustar formalmente el modelo de regresión. Finalmente,
 - c) Abordar el problema de la discriminación salarial.
3. En las siguientes preguntas, conteste la opción verdadera y justifique su respuesta.
- I. En el caso de un modelo algebraico para una línea recta, si se especifica un valor para la variable X , entonces
 - a. Se puede calcular el valor exacto de la variable de respuesta.
 - b. La respuesta calculada al valor independiente siempre dará un residual mínimo.
 - c. El valor calculado de y siempre será la mejor estimación de la respuesta media.
 - d. Ninguna de estas alternativas es correcta
 - II. En un análisis de regresión si $R^2 = 1$, entonces
 - a. $SCRes = SCTot$
 - b. $SCRes = 1$
 - c. $SCReg = SCRes$
 - d. $SCReg = SCTot$
4. Si $\hat{\beta}_0$ y $\hat{\beta}_1$ son las estimaciones de mínimos cuadrados para la ordenada al origen y la pendiente en un modelo de regresión lineal sencilla, demuestre que la ecuación de mínimos cuadrados $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ siempre pasa por el punto $(\bar{x}, \bar{y})$. [Sugerencia: sustituya $\bar{x}$ por x en la ecuación de mínimos cuadrados y use el hecho de que $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$]
5. Recordemos que la matriz hat se define por $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ con elementos diagonales h_{jj} . Muestre que $\mathbf{H}$ es una matriz idempotente.
6. Recuerde que $SCReg = \mathbf{Y}'\mathbf{H}\mathbf{Y}$. Muestre que si

$$CMReg = \frac{SCReg}{p}$$

entonces

$$E(CMReg) = \frac{1}{p}\beta'\mathbf{X}'\mathbf{X}\beta + \sigma^2$$



7. Recuerde que $SCE = \mathbf{Y}'(\mathbf{I} - \mathbf{H})\mathbf{Y}$. Muestre que si

$$CME = \frac{SCE}{n - p}$$

entonces

$$E(CME) = \sigma^2$$

8. Los residuales se pueden escribir como:

$$\mathbf{R} = \hat{\mathbf{e}} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$$

Muestre que $E(\hat{\mathbf{e}}) = 0$ y $Var(\hat{\mathbf{e}}) = (\mathbf{I} - \mathbf{H})\sigma^2$

9. Para un conjunto de datos (x_i, y_i) y un modelo $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, complete los datos de la siguiente salida:

	Estimado	Desviación Estándar	T Calculado	p-value
Intercepto	0.4409	0.1352		0.0115
X	-1.0344		-8.913	1.99E-05
Error estandar residual: 0.4258 con 8 grados de libertad				
Coeficiente R cuadrado:				
Estadística F: 79.4416 sobre 1 y 8 gl, p-value: 1.99e-05				

- Complete los espacios en blanco.
- Escriba la tabla ANOVA.

La tabla ANOVA general para el modelo de regresión lineal simple está dado por:

Fuente de Variación	Suma de cuadrados	Grados de libertad	Cuadrados medios	F	P-valor
Regresión	SCR	1	CMR=SCR/1	CMR/CME	
Error	SCE	$n - 2$	CME=SCE/ $n - 2$		
Total	SCT	$n - 1$			

Recuerde que CME es el mismo error estándar residual al cuadrado.